

1 INTRODUÇÃO

Este documento tem como objetivo atender às orientações encaminhadas por Alessandra para a fase de levantamento de informações da proposta de Trabalho de Conclusão de Curso do curso CI Digital.

As orientações recebidas indicam a necessidade de pesquisar datasets benchmark, compreender as features utilizadas e suas metodologias de extração, identificar trabalhos dedicados à análise e seleção de features e, posteriormente, avaliar a complexidade de implementação. A escolha final não deve decorrer de um único ranking, mas da combinação entre relevância para a detecção de intrusão, recorrência na literatura e viabilidade em hardware.

2 OBJETIVOS DO LEVANTAMENTO

- **Identificar** datasets benchmark de detecção de intrusão que disponibilizem arquivos PCAP e atributos processados.
- **Compreender** como os pacotes são agrupados em fluxos e como as features são calculadas.
- **Levantar** as features originais e agrupá-las por natureza: identificação, volume, temporal, controle TCP, tamanho, taxa e aplicação.
- **Identificar** trabalhos científicos que analisem, classifiquem ou recomendem features.
- **Relacionar** relevância estatística e custo de implementação em hardware.
- **Propor** um conjunto preliminar de features para discussão pelo grupo, sem antecipar a seleção final.

3 METODOLOGIA

O levantamento foi estruturado em **quatro frentes de pesquisa**, correspondentes à divisão sugerida para os integrantes responsáveis pelo estudo das features:

- **UNSW-NB15**, associado ao estudo IGRF-RFE e aos rankings do FSNID.
- **CIC-IDS2017**, associado a estudos de Information Gain, seleção por ensemble e FSNID.

- **CSE-CIC-IDS2018**, associado ao CICFlowMeter-V3 e a trabalhos específicos de seleção de atributos.
- **BoT-IoT** e **ToN-IoT**, associados à padronização NetFlow e aos rankings do FSNID.

Para cada benchmark, foram examinados os seguintes itens:

- Ataques contemplados;
- Complexidade estimada em hardware;
- Definição e direção do fluxo;
- Disponibilidade de PCAP;
- Estudos de seleção e resultados;
- Features disponíveis;
- Ferramenta e metodologia de extração;
- Instituição, ano e aplicação.

4 FUNDAMENTOS PARA INTERPRETAÇÃO DOS RESULTADOS

4.1 Features de pacote e de fluxo

Features de pacote podem ser obtidas durante a interpretação de um único quadro, como protocolo, portas, flags TCP e comprimento. **Features de fluxo** exigem a observação de vários pacotes que compartilham atributos comuns e incluem duração, contagem de pacotes, bytes, intervalos e estatísticas por direção.

4.2 Identificação do fluxo

A identificação normalmente utiliza a **5-tupla** formada por **endereço IP de origem, endereço IP de destino, porta de origem, porta de destino e protocolo**. Em **fluxos bidirecionais**, a chave reversa deve ser reconhecida como pertencente à mesma comunicação.

4.3 Encerramento

Fluxos TCP podem ser finalizados por **FIN** ou **RST**, além de timeout. **Fluxos UDP** não possuem encerramento explícito e dependem de timeout. Essa definição influencia diretamente a duração, as contagens e o momento de emissão do vetor de features.

4.4 Relevância não universal

Não existe um conjunto universalmente aceito de melhores features. A relevância depende do dataset, do tipo de ataque, do balanceamento das classes, do método de seleção e do classificador. Endereços IP e portas podem ainda gerar viés quando identificam diretamente as máquinas ou serviços utilizados nos cenários de ataque.

5 FICHA DE PESQUISA 1 – UNSW-NB15

Item	Informação
Aplicação	Avaliação de sistemas de detecção de intrusão
Dados	Aproximadamente 100 GB de PCAP; 2.540.044 registros processados
Features	49 campos considerando atributos e rótulos
Ferramentas	tcpdump, Argus, Bro-IDS/Zeek e 12 algoritmos adicionais
Fluxo	Atributos nas direções origem-destino e destino-origem
Instituição/ano	Cyber Range Lab, UNSW Canberra; 2015

Fonte: UNSW Canberra, página oficial do UNSW-NB15.

5.1 Ataques

- Analysis
- Backdoors
- DoS
- Exploits
- Fuzzers
- Generic
- Reconnaissance
- Shellcode
- Worms

5.2 Metodologia de extração

O tráfego combina atividades normais e ataques contemporâneos, foi capturado com **tcpdump** e processado com **Argus**, **Bro/Zeek** e algoritmos adicionais. O esquema mistura campos de

cabeçalho, estatísticas por direção, atributos temporais, características TCP, informações da camada de aplicação e contagens agregadas entre conexões.

5.3 Features disponíveis

Categoria	Features
Agregadas	is_sm_ips_ports, ct_state_ttl, ct_srv_src, ct_srv_dst, ct_dst_ltm, ct_src_ltm, ct_src_dport_ltm, ct_dst_sport_ltm, ct_dst_src_ltm
Aplicação	trans_depth, res_bdy_len, ct_flw_http_mthd, is_ftp_login, ct_ftp_cmd
Duração, volume e carga	dur, sbytes, dbytes, spkts, dpkts, sload, dload, sloss, dloss
Identificação e protocolo	srcip, sport, dstip, dsport, proto, state, service
Pacotes e TCP	sttl, dttl, swin, dwin, stcpb, dtcpb, smeansz, dmeansz
Rótulos	attack_cat, label
Temporais	stime, ltime, sintpkt, dintpkt, sjit, djit, tcprtt, synack, ackdat

5.4 Trabalhos de seleção

O **IGRF-RFE** combina Information Gain, importância por Random Forest e Recursive Feature Elimination. O estudo reduziu o espaço de 42 para 23 features e elevou a acurácia multiclasse do MLP de 82,25% para 84,24%.

O **FSNID** destacou, entre outras, estado associado ao protocolo, taxa de bits da origem, quantidade de pacotes origem-destino, comprimento mínimo forward, pacotes por segundo, retransmissões, porta de destino e tempo de estabelecimento TCP.

5.5 Avaliação para hardware

Grupo	Candidatas	Complexidade
Aplicação/agregadas	HTTP, FTP e contagens entre conexões	Alta
Contadores	spkts, dpkts, sbytes, dbytes	Baixa
Diretas	proto, portas	Baixa
Médias	smeansz, dmeansz	Média; requer divisão
TCP	tcprtt, synack, ackdat	Média
Temporais	dur, sintpkt, dintpkt	Baixa a média

Síntese: O **UNSW-NB15** é completo, mas várias features excedem o escopo inicial. Protocolo, duração, pacotes, bytes, tamanho e intervalos são as candidatas mais adequadas.

6 FICHA DE PESQUISA 2 – CIC-IDS2017

Item	Informação
Aplicação	Benchmark para IDS
Dados	PCAP por dia; aproximadamente 2,8 milhões de fluxos processados
Features	Mais de 80 features de fluxo
Ferramenta	CICFlowMeter
Fluxo	Bidirecional; primeiro pacote define forward e backward
Instituição/ano	Canadian Institute for Cybersecurity, University of New Brunswick; 2017

Fonte: Canadian Institute for Cybersecurity, página oficial do CIC-IDS2017.

6.1 Ataques

- Botnet
- DDoS
- DoS Slowloris, Slowhttptest, Hulk e GoldenEye
- FTP-Patator e SSH-Patator
- Heartbleed
- Infiltration
- PortScan
- Web Attack Brute Force, XSS e SQL Injection

6.2 Metodologia de extração

O **CICFlowMeter** identifica fluxos bidirecionais e atualiza estatísticas a cada pacote. O primeiro pacote estabelece a direção forward. Pacotes no sentido reverso atualizam as estatísticas backward. O encerramento pode ocorrer por finalização TCP ou timeout.

6.3 Features disponíveis

Categoria	Features
Atividade	Active Mean, Std, Max, Min; Idle Mean, Std, Max, Min
Bulk	Fwd/Bwd Avg Bytes/Bulk, Packets/Bulk e Bulk Rate
Cabeçalhos e direção	Fwd/Bwd PSH Flags; Fwd/Bwd URG Flags; Fwd/Bwd Header Length
Comprimento backward	Bwd Packet Length Max, Min, Mean e Std
Comprimento forward	Fwd Packet Length Max, Min, Mean e Std
Duração e volume	Flow Duration; Total Fwd/Bwd Packets; Total Length of Fwd/Bwd Packets

Categoria	Features
Estatísticas gerais	Packet Length Min, Max, Mean, Std, Variance; Average Packet Size; Avg Fwd/Bwd Segment Size; Min Seg Size Forward
Flags	FIN, SYN, RST, PSH, ACK, URG, CWE e ECE Flag Count
IAT backward	Bwd IAT Total, Mean, Std, Max e Min
IAT do fluxo	Flow IAT Mean, Std, Max e Min
IAT forward	Fwd IAT Total, Mean, Std, Max e Min
Identificação	Flow ID, IPs, portas, protocolo e timestamp
Rótulo	Label
Subflows e janelas	Subflow Fwd/Bwd Packets e Bytes; Init Win Bytes; act_data_pkt_fwd
Taxas	Flow Bytes/s, Flow Packets/s, Fwd Packets/s e Bwd Packets/s

6.4 Trabalhos de seleção

Kurniabudi et al. aplicaram Information Gain. Random Forest atingiu 99,86% de acurácia com 22 features; J48 atingiu 99,87% com 52, porém com maior tempo de execução.

No **FSNID**, as três principais foram Destination Port, PSH Flag Count e Fwd IAT Min. Outros métodos destacaram Subflow Bwd Bytes, Init Win Bytes Forward, Fwd IAT Mean, Min Seg Size Forward, Packet Length Mean, Packet Length Std e Min Packet Length.

6.5 Avaliação para hardware

Complexidade	Features
Alta	Variância; desvio-padrão; active/idle; bulk; subflow
Baixa	Duração; contagem de pacotes/bytes; mínimo/máximo; comprimentos de cabeçalho; flags TCP
Baixa/média	IAT mínimo e máximo
Média	Médias; bytes/s; pacotes/s; razão download/upload

Síntese: O **CIC-IDS2017** é a referência mais direta para compreender o funcionamento do **CICFlowMeter**, mas a literatura sustenta a utilização de um subconjunto menor.

7 FICHA DE PESQUISA 3 – CSE-CIC-IDS2018

Item	Informação
Aplicação	IDS em infraestrutura organizacional simulada
Dados	PCAP e logs por máquina e dia
Features	Aproximadamente 80 a 83
Ferramenta	CICFlowMeter-V3
Fluxo	Bidirecional
Infraestrutura	5 departamentos, 420 máquinas e 30 servidores
Instituições/ano	Canadian Institute for Cybersecurity e Communications Security Establishment; 2018

Fonte: University of New Brunswick, página oficial do CSE-CIC-IDS2018.

7.1 Ataques

- Ataques Web
- Botnet
- Brute-force
- DDoS
- DoS
- Heartbleed
- Infiltração

7.2 Metodologia e features

O **CICFlowMeter-V3** produz fluxos bidirecionais. A documentação registra encerramento TCP por FIN e encerramento UDP por timeout, cujo valor pode ser configurado. As categorias de features coincidem em grande parte com as do **CIC-IDS2017**: duração, volume, comprimento, taxas, IAT, cabeçalhos, flags, bulk, subflows, janelas TCP e períodos active/idle.

Cuidado documental: A descrição oficial contém pequenas inconsistências terminológicas em algumas linhas. Para a implementação, os cálculos devem ser validados contra o código da ferramenta ou um modelo de referência em software.

7.3 Trabalho específico de seleção

Göcs e Johanyák aplicaram seis métodos de avaliação de features, normalizaram os escores e construíram um ranking médio. Os subconjuntos foram testados separadamente para cinco ataques.

Ataque	Features	Classificador	Acurácia
FTP Brute Force	8	Random Forest	1,00000
SQL Injection	26	Decision Tree	0,99999
SSH Brute Force	7	Random Forest	0,99999
Web Brute Force	44	Decision Tree	0,99994
XSS	10	Random Forest	0,99999

O resultado confirma que não existe uma única quantidade de features adequada para todos os ataques.

7.4 Avaliação para hardware

As candidatas mais viáveis são duração, pacotes e bytes por direção, mínimo e máximo do comprimento, comprimentos de cabeçalho, contagens de flags, IAT mínimo/máximo, janela TCP inicial e quantidade de pacotes forward com payload.

Síntese: O CSE-CIC-IDS2018 permite avaliar generalização e ataques mais recentes, mas seu volume recomenda a seleção de PCAPs ou fluxos representativos para o ambiente de simulação.

8 FICHA DE PESQUISA 4 – BOT-IOT E TON-IOT

8.1 BoT-IoT

Item	Informação
Aplicação	Detecção e análise forense de botnets em IoT
Dados	PCAP de aproximadamente 69,3 GB; mais de 72 milhões de registros
Features	46 campos na versão completa, conforme critério de contabilização
Ferramenta	Argus e algoritmos adicionais
Instituição/ano	UNSW Canberra; 2018/2019

Fonte: UNSW Canberra, página oficial do BoT-IoT.

8.1.1 Ataques

- Data Exfiltration
- DDoS
- DoS
- Keylogging
- OS Scan
- Service Scan

8.1.2 Features

Categoria	Features
Agregadas	bytes e pacotes por IP; pacotes por protocolo e porta; taxa por protocolo/IP; conexões de entrada por IP
Identificação/tempo	pkSeqID, stime, ltime, seq, saddr, daddr, sport, dport
Protocolo/estado	flgs, flgs_number, proto, proto_number, state, state_number
Rótulos	attack, category, subcategory
Volume/estatísticas	pkts, bytes, dur, mean, stddev, sum, min, max, spkts, dpkts, sbytes, dbytes, rate, srate, drate

8.1.3 Seleção e hardware

O FSNID e métodos comparados destacaram protocolo, estado, horário de início, pacotes agrupados por estado/protocolo/IP, conexões de entrada, duração, pacotes destino-origem e bytes destino-origem. As agregações por IP ou janelas globais exigem estado compartilhado entre vários fluxos. **Protocolo, estado, duração, pacotes e bytes por direção** são mais viáveis.

8.2 ToN-IoT

Item	Informação
Aplicação	IDS para IoT, IIoT e Industry 4.0
Dados	PCAP, logs Zeek, CSV, telemetria, Windows e Linux
Features de rede	Aproximadamente 44
Ferramenta	Zeek/Bro
Instituição/ano	UNSW Canberra; 2019/2020

Fonte: UNSW Canberra, página oficial do ToN-IoT.

8.2.1 Ataques

- Backdoor
- DDoS
- DoS
- Injection
- MITM
- Password
- Ransomware
- Scanning
- XSS

8.2.2 Features

Categoria	Features
DNS	consulta, classe, tipo, código de resposta, AA, RD, RA e rejeição
Eventos	nome, informação adicional e notice
HTTP	profundidade, método, URI, versão, corpo da requisição/resposta, status, user agent e MIME
Identificação	timestamp, IPs, portas, protocolo, serviço, estado e duração
Rótulos	label e type
SSL/TLS	versão, cifra, sessão retomada, estabelecimento, subject e issuer
Volume	bytes, pacotes, bytes IP e bytes perdidos por direção

8.2.3 Seleção e hardware

Os rankings destacam protocolo de aplicação, portas, duração, bytes de destino, bytes perdidos, timestamp, características DNS e cumprimentos HTTP. A maior parte dessas variáveis de aplicação exigiria inspeção de camada 7. Para o escopo Ethernet/IPv4/TCP/UDP, são aproveitáveis protocolo, portas, estado, duração, pacotes e bytes.

9 CONJUNTO PADRONIZADO NETFLOW

Sarhan et al. converteram os PCAPs de UNSW-NB15, BoT-IoT, ToN-IoT e CSE-CIC-IDS2018 para um esquema comum de **12 features NetFlow**. A proposta busca facilitar comparação entre datasets e utilizar atributos mais simples de obter em redes reais.

Feature	Descrição	Observação para o TCC
FLOW_DURATION_MILLISECONDS	Duração do fluxo	Timestamps e subtração
IN_BYTES	Bytes de entrada	Contador/acumulador
IN_PKTS	Pacotes de entrada	Contador
IPV4_DST_ADDR	Endereço IPv4 de destino	Identificação; não recomendado ao classificador sem análise de viés
IPV4_SRC_ADDR	Endereço IPv4 de origem	Identificação; não recomendado ao classificador sem análise de viés
L4_DST_PORT	Porta de destino	Recorrente em estudos de seleção
L4_SRC_PORT	Porta de origem	Pode identificar cliente/serviço; avaliar viés
L7_PROTO	Protocolo de aplicação	Fora do escopo inicial; alta complexidade
OUT_BYTES	Bytes de saída	Contador/acumulador
OUT_PKTS	Pacotes de saída	Contador
PROTOCOL	Protocolo IP	Baixa complexidade
TCP_FLAGS	Acumulação de flags TCP	Baixa complexidade

Os autores observaram desempenho semelhante aos conjuntos originais em parte das classificações binárias, mas desempenho inferior em algumas tarefas multiclasse. Isso torna o conjunto uma boa linha de base, não uma resposta definitiva.

Fonte: Sarhan et al., NetFlow Datasets for Machine Learning-Based Network Intrusion Detection Systems, 2021.

10 COMPARAÇÃO CONSOLIDADA

Categoria	UNSW	CIC-17	CIC-18	BoT	ToN
Bytes por direção	Sim	Sim	Sim	Sim	Sim
Camada de aplicação	Sim	Não	Não	Parcial	Sim
Duração	Sim	Sim	Sim	Sim	Sim
Estado/flags TCP	Sim	Sim	Sim	Sim	Sim
Intervalos	Sim	Sim	Sim	Parcial	Parcial
Pacotes por direção	Sim	Sim	Sim	Sim	Sim
Portas	Sim	Sim	Sim	Sim	Sim
Protocolo	Sim	Sim	Sim	Sim	Sim
Tamanho dos pacotes	Sim	Sim	Sim	Sim	Parcial
Taxas	Sim	Sim	Sim	Sim	Parcial

11 ANÁLISE PRELIMINAR DE COMPLEXIDADE

Complexidade	Features	Recursos principais
Alta	Desvio-padrão	Variância e raiz quadrada
Alta	Protocolo L7	Inspeção de payload
Alta	Agregações por host/janela	Estado compartilhado entre fluxos
Baixa	Protocolo, portas	Seleção de campos e registradores
Baixa	Pacotes e bytes por direção	Contadores e acumuladores
Baixa	Flags TCP	Contadores por flag
Baixa	Duração	Timestamps e subtração
Baixa	Mínimo e máximo	Comparadores e registradores
Média	Médias	Acumulador e divisão
Média	Pacotes/s e bytes/s	Divisão e escala temporal
Média	IAT médio	Timestamps, soma e divisão
Média/alta	Variância	Soma de quadrados e maior largura

12 CONJUNTO PRELIMINAR RECOMENDADO

O conjunto abaixo é uma lista de candidatos para avaliação do grupo. Sua finalidade é orientar a discussão e a arquitetura inicial, não encerrar a seleção.

Nº	Feature	Obtenção	Complexidade
1	Protocolo	Campo IPv4	Baixa
2	Porta de destino	Campo TCP/UDP	Baixa
3	Duração	Último timestamp - primeiro	Baixa
4	Pacotes forward	Contador	Baixa
5	Pacotes backward	Contador	Baixa
6	Bytes forward	Acumulador	Baixa
7	Bytes backward	Acumulador	Baixa
8	Comprimento mínimo	Comparador	Baixa
9	Comprimento máximo	Comparador	Baixa
10	Comprimento total forward	Acumulador	Baixa
11	Comprimento total backward	Acumulador	Baixa
12	IAT mínimo forward	Timestamp e comparador	Baixa/média
13	IAT mínimo backward	Timestamp e comparador	Baixa/média
14	SYN Count	Contador	Baixa
15	ACK Count	Contador	Baixa
16	FIN Count	Contador	Baixa

Nº	Feature	Obtenção	Complexidade
17	RST Count	Contador	Baixa
18	PSH Count	Contador	Baixa
19	Header Length forward	Acumulador	Baixa
20	Header Length backward	Acumulador	Baixa

Segunda etapa: Tamanho médio, IAT médio, pacotes por segundo e bytes por segundo podem ser acrescentados após a validação do núcleo básico. Variância, desvio-padrão, bulk, active/idle e inspeção de camada 7 devem depender do cronograma e dos recursos disponíveis.

13 RECOMENDAÇÕES PARA CONTINUIDADE

1. Definir formalmente se o fluxo do projeto será bidirecional e como a direção forward será estabelecida.
2. Definir os timeouts de TCP e UDP e o tratamento de FIN e RST.
3. Estabelecer a quantidade máxima de fluxos simultâneos e a política para tabela cheia.
4. Criar um modelo de referência em software para extrair as mesmas features dos PCAPs.
5. Comparar o modelo de referência com Wireshark, tshark, Zeek, Argus, nProbe ou CFlowMeter, conforme a feature.
6. Avaliar um classificador simples com o conjunto completo e com o subconjunto proposto.
7. Estimar largura dos registradores, memória, divisores, latência e frequência antes da seleção final.
8. Registrar explicitamente features excluídas e a razão da exclusão: viés, camada 7, alto custo ou ausência de relevância consistente.

14 CONCLUSÃO

O levantamento mostra que duração, protocolo, portas, quantidade de pacotes, quantidade de bytes, estatísticas de comprimento, intervalos entre pacotes e flags TCP são as categorias mais recorrentes entre os benchmarks. Os trabalhos de seleção confirmam que subconjuntos menores podem preservar ou melhorar a classificação, mas também demonstram que a importância varia conforme o ataque e o método utilizado.

Para o desenvolvimento em Verilog, recomenda-se iniciar com features obtidas por campos de cabeçalho, contadores, acumuladores, comparadores e subtrações. Médias e taxas podem constituir uma segunda etapa. Features que exigem variância, raiz quadrada, inspeção da camada de aplicação ou agregação global devem ser avaliadas apenas após a estabilização da arquitetura básica.

A escolha final deverá combinar três evidências: recorrência nos datasets, indicação em trabalhos de seleção e custo técnico de implementação. Assim, o conjunto preliminar apresentado constitui uma base justificável para discussão com o grupo e com os orientadores, sem antecipar uma decisão ainda dependente de experimentação.

15 REFERÊNCIAS

DAS, A. et al. An FPGA-Based Network Intrusion Detection Architecture. IEEE Transactions on Information Forensics and Security, 2008.

GÖCS, L.; JOHANYÁK, Z. C. Identifying Relevant Features of CSE-CIC-IDS2018 Dataset for the Development of an Intrusion Detection System. Information Discovery and Delivery, 2023.

KORONIoTIS, N. et al. Towards the Development of Realistic Botnet Dataset in the Internet of Things for Network Forensic Analytics: Bot-IoT Dataset. Future Generation Computer Systems, v. 100, p. 779-796, 2019.

KURNIABUDI et al. CICIDS-2017 Dataset Feature Analysis With Information Gain for Anomaly Detection. IEEE Access, v. 8, p. 132911-132921, 2020. DOI: 10.1109/ACCESS.2020.3009843.

MOUSTAFA, N.; SLAY, J. UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems. MilCIS, 2015. DOI: 10.1109/MilCIS.2015.7348942.

SARHAN, M. et al. NetFlow Datasets for Machine Learning-Based Network Intrusion Detection Systems. BDTA/WiCON, 2021. DOI: 10.1007/978-3-030-72802-1_9.

TROVATO, M. et al. Feature Selection for Network Intrusion Detection. KDD, 2025.

YIN, Y. et al. IGRF-RFE: A Hybrid Feature Selection Method for MLP-Based Network Intrusion Detection on UNSW-NB15 Dataset. Journal of Big Data, v. 10, 2023.

UNIVERSITY OF NEW BRUNSWICK. CIC-IDS2017 e CSE-CIC-IDS2018: páginas oficiais dos datasets.

UNSW CANBERRA. UNSW-NB15, BoT-IoT e ToN-IoT: páginas oficiais dos datasets.